Contents

CUDA 语法稀有性不是训练不稳定的根因：来自 98,533 个 token 的条件概率证据 1
摘要 . . . 2
1. 引言 . . . 2
1.1 背景 . . . 2
1.2 问题陈述 . . . 2
1.3 研究缺口 . . . 2
1.4 研究问题 . . . 3
1.5 研究意义 . . . 3
2. 相关工作 . . . 3
2.1 CUDA Agent 的因果链（本研究检验的对象） . . . 3
2.2 DR. KERNEL：训练–推理不匹配作为替代解释 . . . 3
2.3 精度不匹配与 off-policy 漂移 . . . 3
2.4 闭源 API 的概率可得性边界 . . . 4
2.5 与本研究的分工 . . . 4
3. 方法 . . . 4
3.1 采集架构 . . . 4
3.2 任务 . . . 4
3.3 反馈条件（干预） . . . 4
3.4 分类与统计 . . . 4
3.5 规模 . . . 5
4. 结果 . . . 5
4.1 RQ1：CUDA 词汇的概率显著更高 . . . 5
4.2 RQ2：上下文效应远强于 token 类型 . . . 5
4.3 RQ3：压缩反馈未能降低低概率率 . . . 5
4.5 跨模型复现：本地 Qwen3-4B 一轮 . . . 6
4.6 低概率 token 的构成 . . . 6
5. 讨论 . . . 6
5.1 因果链起点不成立 . . . 6
5.2 与 CUDA Agent 原文量级的对照（须谨慎解读） . . . 6
5.3 低概率来自失败反馈后的上下文 . . . 7
5.4 干预无效的含义 . . . 7
5.5 方法启示 . . . 7
6. 局限 . . . 7
7. 结论 . . . 8
参考文献 . . . 8
附录 A：局限补充 . . . 8
附录：复现 . . . 8

CUDA 语法稀有性不是训练不稳定的根因：来自 98,533 个 token 的条件概率证据

作者： leo-grayrat **机构：** 独立研究 **日期：** 2026-10-17

摘要

背景: CUDA Agent 将 PPO 训练不稳定归因于 "CUDA 在预训练语料中占比低于 0.01%，导致基础模型对 CUDA 词元的条件概率极低，进而使重要性比率爆炸"，并把该论断作为论文标题中的 "根因"。该因果链的起点——CUDA 专属词汇是否构成低概率尾部——此前未被独立检验。

目的: 检验该因果链起点是否成立，若否，识别低概率真正的来源。

方法: 不使用 agent 框架（其工具调用参数不受 `logprobs` 覆盖），改为多轮纯对话采集：模型在回复正文中直接输出 kernel 代码，由驱动程序写入文件、调用独立评测器、并构造反馈文本进入下一轮。模型为 `deepseek-chat`（非推理），4 道 Triton 任务 × 2 种反馈条件（完整/截断）× 16 次重复，共 127 次有效运行、98,533 个携带 logprob 的正文 token。

发现: (1) CUDA/Triton 词汇的低概率率**显著低于**其他 token——严格定义下 0.26% vs 0.84%（Fisher $p = 0.0007$），宽松定义下 0.49% vs 0.84%（$p = 0.0070$），两种边界方向一致。(2) 上下文效应远强于 token 类型：`after_failure`（收到评测失败反馈后）低概率率 **4.30%**，是 `initial`（0.94%）的 4.6 倍。(3) 全库最低的 token 全部是自然语言词，无一为代码 token。(4) 压缩反馈**未能**降低低概率率（完整 0.71% vs 截断 0.95%）。

意义: CUDA Agent 的因果链起点不成立；其声称的 "根因" 更可能来自多轮 agent 轨迹中失败反馈带来的分布外上下文，而非 CUDA 语法的稀有性。

关键词: CUDA Agent, 训练不稳定, 逐 token logprob, 分布外上下文, Triton

---

1. 引言

1.1 背景

CUDA kernel 的自动优化是 LLM agent 的一个重要应用场景：agent 反复生成 kernel 代码、编译、测量、根据反馈修改，最终目标是产出比 `torch.compile` 更快的实现。这一流程需要在多轮工具调用与环境反馈中维持稳定的策略改进。

CUDA Agent 报告称，这类训练在约第 17 步出现崩溃，并给出了一个因果链：CUDA 在预训练语料中占比 $< 0.01\%$ → 基础模型与 CUDA 分布严重错配 → 采样出大量低概率 CUDA 词元 → PPO 重要性比率爆炸 → 训练崩溃。该论断被置于论文标题 "训练不稳定的根因" 之下。

1.2 问题陈述

该因果链的起点依赖一个可检验的假设：**CUDA 专属词汇在生成时构成低概率尾部。**这与三项直觉相抵触：

第一，CUDA 代码中的绝大多数 token 并不专属 CUDA（`for`、`if`、`float`、`int`、运算符），真正专属的只有 `threadIdx.x`、`__shared__`、`__syncthreads()` 等少数标识符，而它们 "恰恰非常固定、非常模式化"。

第二，生成时的关键量是**当前上下文下的条件概率**，与预训练语料中的绝对占比没有直接关系。

第三，论文自身的数据构成反证：其基础模型并非 "不会写 CUDA"（原始模型总体正确率 74%，Level 1 达 90%）。

1.3 研究缺口

CUDA Agent 未公开逐 token 的 Critic value、advantage 或生成概率，因此无法从内部观测验证该因果链。而在闭源 API 侧，工具调用参数不受 `logprobs` 覆盖（这是多家厂商的一致行为，被普遍解读为防止蒸馏），使得基于 agent 框架的逐 token 分析在参数部分不可行。

1.4 研究问题

本研究检验以下问题：

- **RQ1**：CUDA/Triton 专属词汇的低概率率是否显著高于其他 token?
- **RQ2**：低概率率是否随上下文类型变化？若变化，哪一类上下文最高?
- **RQ3**：压缩环境反馈能否降低低概率率?

1.5 研究意义

若 RQ1 的答案为否，则 CUDA Agent 的因果链起点不成立，其 "根因" 叙述需要改写，而针对 "多喂 CUDA 语料" 一类干预的合理性也随之减弱。

---

2. 相关工作

2.1 CUDA Agent 的因果链（本研究检验的对象）

CUDA Agent 报告称直接 RL 训练在 17 步后崩溃，并给出如下因果链：

> CUDA 代码仅占预训练数据的 0.01% → 基础模型的学习先验与 CUDA 内核编码所需分布偏差显著 → 采样出大量低概率 CUDA 代码 token → 当训练与推理引擎使用不同数值精度（BF16 vs FP16）时，在精度下限附近的微小误差导致重要性比率 ( ) 剧烈波动或爆炸。

原文给出的关键量级是 **(a |s) 10** ——即 CUDA token 的条件概率处于数值下限。其解法为三步预热（单轮 RL 热身 → 拒绝微调初始化 Actor → 价值预训练初始化 Critic），以绕开该数值崩溃点。

本研究的 RQ1 直接检验其中的 "采样出大量低概率 CUDA 代码 token" 这一环。

2.2 DR. KERNEL：训练–推理不匹配作为替代解释

DR. KERNEL（Triton kernel 生成的 RL）独立研究了同类不稳定现象，并考察了两个假设：(1) 训练–推理不匹配导致的优化不稳定；(2) 优化目标与有意义的加速不匹配。

其采用几何平均不匹配拒绝采样（MRS），仅保留几何平均重要性比 w [0.999, 1.001] 的样本，并施加严格的 token 级否决——若任一单个 token 的似然比 _train/ _rollout 低于 10 ，则拒绝整个序列。

关键结论是：MRS 成功稳定了训练动态，但**并未从根本上提升性能上限。**这说明训练–推理不匹配虽能解释不稳定性，但单独解决它并不充分。

该结论与本研究方向一致：不稳定性更多来自训练/推理两侧的分布差异（一种上下文层面、而非词表层面的现象），而非 "CUDA 词汇稀有" 这一词表属性。

2.3 精度不匹配与 off-policy 漂移

CUDA Agent 引用的相关工作包括：Jet-RL、*Precision Mismatch in Reasoning Models*、*First-Order Approximation for Stable LLM-RL Training*，以及 Liu 等人关于 "高效 RL 框架会引入 off-policy 训练" 的分析。这些工作共同刻画了一类机制：**当 token 概率处于数值下限时，微小的数值差异在 PPO 的比值意义上不再微小。**

本研究补充的是该机制的前提检验：在本研究的条件下，CUDA 词汇的条件概率**并不处于下限。**

2.4 闭源 API 的概率可得性边界

多项证据表明，工具调用参数不被 `logprobs` 覆盖是厂商的策略选择而非技术限制：OpenAI 论坛上该问题持续两年未获答复；Anthropic、Gemini 等接受 `logprobs` 参数但静默返回 none；三篇关于“闭源模型能否支持科学推断”的论文均将“隐藏完整概率分布”列为障碍（其中一篇直接引用 Carlini 等从概率分布反推模型规模的工作作为厂商动机的解释）。

这解释了本研究为何采用无工具的多轮对话采集架构。

2.5 与本研究的分工

上述工作均从**训练侧**观测或干预不稳定性。本研究不做训练，而是从**推理侧**直接测量条件概率分布，检验因果链的第一个环节是否成立。

---

3. 方法

3.1 采集架构

不使用 agent 框架。驱动程序 `loop_driver.py` 直接向 chat-completions 端点发起多轮对话：

1. 第 1 轮：发送任务描述（含 `reference.py`）与要求（必须使用 Triton kernel；在正文中以围栏代码块输出完整 `candidate.py`；不使用任何工具）。
2. 模型在**正文**中输出代码。工具未被提供，因此代码必然落在 `message.content` 中——而该字段受 `logprobs` 覆盖。
3. 驱动解析代码块、写入 `candidate.py`、调用独立评测器。
4. 驱动将评测结果构造为反馈文本，作为新的 user message 进入下一轮。

前置验证：在正式采集前以单轮请求确认可行性，测得 **448/448** 个代码块内 token 均携带 logprob。该验证通过后路线方成立。

模型：`deepseek-chat`（非推理）。选用理由为实测结果：`deepseek-flash`（推理模型）在 `max_tokens=4000` 时预算被思考耗尽、`content` 返回空；`deepseek-chat` 的 `reasoning_tokens` 恒为 0，内容直接落在 `content`。

3.2 任务

4 道 Triton 任务：`row_reduce`(行归约)、`vector_affine`(逐元素仿射)、`layernorm_rows`(行归一化)、`softmax_rows`(行 softmax)。前两道为常规集，后两道为留出集。

3.3 反馈条件（干预）

- **完整 (full)**：评测器的完整输出（编译错误全文、正确性对比、计时）。
- **截断 (truncated)**：单行摘要（`compilation failed` / `output mismatch` / `correct`）。

两条件在采集开始前定死并实现，采集期间未修改。

3.4 分类与统计

token 类型：按关键词表在**全部 content token** 上匹配，不依赖任何分段信息。为检验稳健性，同时在两种定义边界下各计算一次：

- **宽松表**：包含 Triton API 名（`tl`、`load`、`store`、`zeros`、`arange`、`atomic_add`、`num_warps` 等 28 项）。
- **严格表**：仅包含无歧义拼写（`tl`、`num_warps`、`constexpr`、`program_id` 及 CUDA 原生标识符）。

上下文类型：由轮次与上一轮评测结果决定——`initial`（第 1 轮）、`after_success`（上轮评测通过）、`after_failure`（上轮评测失败）。

观测量：低概率定义为 `logprob ≤ -2`（自然对数）。组间比较使用 Fisher 精确检验（双侧）。

3.5 规模

4 任务 × 2 条件 × 16 重复 = 128 次运行，其中 127 次产出有效数据。

---

4. 结果

共 98,533 个 content token。

4.1 RQ1: CUDA 词汇的概率显著更高

分组	n	平均 logprob	低概率率（ -2）
宽松表命中	4,524	-0.038	**0.49%**
宽松表未命中	94,009	-0.062	0.84%
严格表命中	2,344	-0.013	**0.26%**
严格表未命中	96,189	-0.062	0.84%

Fisher 精确检验：宽松表 $\mathbf{p = 0.0070}$，严格表 $\mathbf{p = 0.0007}$。

CUDA/Triton 词汇的低概率率显著低于其他 token，且两种定义边界下方向一致。

作为对照，结构 token（`for`、`if`、`return` 等无替代写法的词）的低概率率为 1.54%，高于其他 token 的 0.81%——即“低概率”与“是否为 CUDA 词汇”无关，甚至方向相反。

4.2 RQ2: 上下文效应远强于 token 类型

上下文	n	平均 logprob	低概率率	p10
after_failure	3,143	-0.276	**4.30%**	-0.898
after_success	46,719	-0.033	0.48%	-0.000
initial	48,671	-0.074	0.94%	-0.049

`after_failure` 的低概率率是 `initial` 的 4.6 倍、`after_success` 的 9 倍。

按任务：`softmax_rows` 1.20% > `row_reduce` 0.99% > `layernorm_rows` 0.53% > `vector_affine` 0.47%。

4.3 RQ3: 压缩反馈未能降低低概率率

条件	n	低概率率
完整反馈	50,238	0.71%
截断反馈	48,295	0.95%

截断反馈不仅未降低低概率率，反而略高（0.95% vs 0.71%）。**该干预无效。**

4.5 跨模型复现：本地 Qwen3-4B 一轮

在 DeepSeek 路线之前，另用**完全不同的技术栈**做过一轮：本地 vLLM 服务 + `Qwen3-4B-AWQ`（4-bit 量化）+ agent 框架（OpenCode）+ 记录代理。该轮采得 `row_reduce` 单任务的 12 次运行、15,987 个 token。

全量匹配下的结果：

分组	n	低概率率（-2）
CUDA/Triton API 名	451	**1.55%**
其他	15,536	0.95%

Fisher p = 0.211（不显著），方向与 DeepSeek 轮一致——**CUDA 词汇不低于其他 token。**

该轮的意义与局限：

- 它是**跨模型、跨推理引擎、跨采集架构的独立复现**：模型（4B 量化 vs 商用 API）、推理后端（本地 vLLM vs 官方 API）、采集路径（agent 工具调用 vs 纯对话）三者全不相同，方向仍然一致。
- 但样本量小（451 个 API 名 token，仅 1 道任务），**未达显著。**
- 该轮的**细分结论（分位数、工具维度、位置效应、"API 选择点"机制）全部撤回**——原因是分类偏差，详见 5.4。

结论：两轮数据在"CUDA 词汇不构成低概率尾部"这一点上方向一致，DeepSeek 轮提供了统计显著性，Qwen 轮提供了跨栈稳健性。

4.6 低概率 token 的构成

全库最低的 token：

```
' constants'   -17.746   row_reduce      full       after_success
' backed'      -11.271   row_reduce      full       after_success
' small'       -10.725   softmax_rows    full       after_success
' computing'   -10.361   vector_affine   truncated  after_success
' wrong'       -10.056   softmax_rows    full       after_success
' weight'       -9.681   layernorm_rows  truncated  after_failure
```

无一为代码 token；全部为自然语言词。

---

5. 讨论

5.1 因果链起点不成立

RQ1 的答案是否定的，且方向与假设相反。CUDA/Triton 专属词汇不仅不构成低概率尾部，其低概率率还显著低于其他 token。这直接否证了"CUDA 语法稀有 → 低概率"这一环节。

可能的机制是：这些 token 高度模式化、上下文约束极强（`tl.load` 的后续位置几乎确定），因而模型在它们上的条件概率接近 1。这与引言中"非常固定、非常模式化"的观察一致。

5.2 与 CUDA Agent 原文量级的对照（须谨慎解读）

CUDA Agent 原文给出的关键量级是 $(\mathbf{a}\,|\mathbf{s}) \quad \mathbf{10}$ ，即 CUDA token 的条件概率处于数值下限。本研究测得的是**接近 1.0**。两者相差约九个数量级，这个差异**不能**直接解读为对原文的否证，因为至少有两处条件不同：

1. **模型状态**：原文测的是**未经过任何微调的基础模型**在训练 rollout 中的行为；本研究测的是**已对齐的商用模型**（deepseek-chat）在推理 API 下的行为。对齐过程（SFT + RLHF）本身就会大幅提升常用代码模式的概率。
2. **采样条件**：原文是训练 rollout（含特定温度、截断、精度）；本研究是标准推理请求。

因此本研究的结论应当表述为：**在已对齐模型的推理条件下，CUDA 词汇不构成低概率尾部。**这对原文的“根因”叙事构成一个**待解释的张力**——若该叙事成立，则需要说明为何已对齐模型上该现象完全消失；若不成立，则原文的不稳定更可能来自 5.3 所述的上下文因素。

一个可检验的区分：若在未微调的基础模型上重复本实验，CUDA token 的低概率率应当显著升高。本研究未能执行该对照（需要基础模型权重）。

5.3 低概率来自失败反馈后的上下文

RQ2 显示上下文效应强于 token 类型一个数量级。`after_failure` 的低概率率是 `initial` 的 4.6 倍，这与“长 agent 轨迹中累积的分布外输入导致偏离”的解释一致：评测失败的反馈文本（编译错误、不匹配的输出）本身是训练分布中稀有的输入形态。

这一结果与 DR. KERNEL 的发现方向一致：该工作用几何平均不匹配拒绝采样与 token 级否决处理训练–推理不匹配，稳定了训练动态，但未能提升性能上限。本研究从推理侧补充了一条独立证据：**不稳定性更可能与上下文分布有关，而非词表属性。**

值得注意的是，`after_success` 反而低于 `initial`——成功反馈收窄了后续的候选空间。

5.4 干预无效的含义

RQ3 表明，压缩反馈的**信息量**并不减少低概率。结合 5.3，低概率的来源是“失败这一事件本身改变了上下文分布”，而非“反馈文本太长”。因此针对反馈长度的压缩并非有效干预。

5.5 方法启示

本研究早期的一轮（本地 vLLM + 4B 模型）曾得出“CUDA token 低概率率 10%、$p = 0.0156$”的结论，后经核查为**分类偏差**：分类器在散文段刻意排除了若干 Triton 关键词（以避免与英文散文混淆），使该类别仅捕获 20/451 个 token，而其中恰含两个极端采样值。同一个词 `load` 因此被切进两类：归入散文的 6 次平均 -0.044、零低概率；归入 Triton 的 4 次平均 -1.034、25% 低概率。

教训：任何按类别做的统计，必须先做“放宽定义边界后结论是否仍成立”的稳健性检查。本研究的正式结果因此报告了两种定义边界。

---

6. 局限

1. **模型**：使用 `deepseek-chat`，而非 CUDA Agent 的 Seed1.6。结论不能直接外推到后者——尽管 `deepseek-chat` 已是公开 API 中能力最接近的一档。
2. **任务**：4 道，均为元素级或归约级，未包含算子融合、tiling、launch 配置等更接近真实优化的任务类型。
3. **样本分布**：`after_failure` 仅占 4.3% 的 token，其 4.30% 的低概率率基于 3,143 个样本。
4. **未测**：低概率是否真的导致 PPO 重要性比率爆炸（需实际训练）；train-inference mismatch 的贡献比重（需双引擎对照）；Seed1.6 特定权重上的表现（需其权重）。
5. **单一采集路径**：所有数据来自同一驱动与同一 API，未做跨引擎复现。

---

7. 结论

本研究以 127 次运行、98,533 个携带条件概率的 token 检验了 CUDA Agent 因果链的起点，发现：

1. CUDA/Triton 专属词汇的低概率率**显著低于**其他 token（0.26% vs 0.84%，p = 0.0007），因果链起点不成立。
2. 低概率真正集中在**失败反馈之后**的上下文（4.30%），约为初始上下文的 4.6 倍。
3. 压缩环境反馈**不能**降低低概率率。

因此，把 CUDA 训练的困难归因于“CUDA 语法稀有”缺乏经验支持；更可能的来源是多轮 agent 轨迹中的失败反馈改变了输入分布。后续工作应以此为出发点设计干预，而非增加 CUDA 语料。

参考文献

1. **CUDA Agent: Large-Scale Agentic RL for High-Performance CUDA Kernel Generation.** arXiv:2602.24286. （本研究检验其因果链；其给出的量级为 （a |s ） 10 ）
2. **DR. KERNEL: Reinforcement Learning Done Right for Triton Kernel Generations.** arXiv:2602.05885. （独立的同类不稳定研究；提出几何平均不匹配拒绝采样与 token 级否决，发现稳定化不能提升性能上限）
3. Liu et al. *Your Efficient RL Framework Secretly Brings You Off-Policy RL Training.* （off-policy 漂移机制）
4. Jet-RL.（精度不匹配导致的重要性比率爆炸）
5. *Precision Mismatch in Reasoning Models.*（CUDA Agent 引用）
6. *First-Order Approximation for Stable LLM-RL Training.*（稳定性分析）
7. Carlini et al. *Stealing Part of a Production Language Model.*（从概率分布反推模型细节，厂商限制 logprobs 的动机）
8. *How Open Must Language Models be to Enable Reliable Scientific Inference?* (2026).（闭源模型作为科学仪器的三项障碍）
9. *Surrogate Fidelity: When Can Open LLMs Explain Closed Ones?* (Meta).（指出主流 API 至多暴露 output token 的 log-probabilities）
10. *Log Probability Tracking of LLM APIs* (INRIA, OpenReview).（首 token logprobs 用于监控 API 漂移；审稿意见点明“多数提供方不提供 logprobs”这一根本限制）

附录 A：局限补充

缺失的关键对照：本研究未能在**未微调的基础模型**上重复实验（需要基础模型权重）。5.2 指出，这是区分“CUDA 词汇本身稀有”与“对齐后该现象消失”的唯一直接办法。若条件允许，该对照应优先补上。

未测：低概率是否真的导致 PPO 重要性比率爆炸（需实际训练）；train-inference mismatch 的贡献比重（需双引擎对照）。

附录：复现

```
# 最小验证（路线是否成立）
python lowprob-attribution/scripts/check_plaintext_logprobs.py --model deepseek-chat --max-tokens 16000

# 正式采集
python lowprob-attribution/scripts/loop_driver.py \
```

```
    --tasks row_reduce vector_affine \
    --conditions full truncated --repeats 16 --max-turns 8 \
    --model deepseek-chat --max-tokens 8192 \
    --runs-root lowprob-attribution/runs-formal
python lowprob-attribution/scripts/loop_driver.py \
    --heldout --tasks layernorm_rows softmax_rows \
    --conditions full truncated --repeats 16 --max-turns 8 \
    --model deepseek-chat --max-tokens 8192 \
    --runs-root lowprob-attribution/runs-formal

# 分析
python lowprob-attribution/scripts/analyze_loop.py lowprob-attribution/runs-formal
```